

3Dビンパッキング(NEDO積付アルゴリズムコンテスト):構築ヒューリスティック以外のアプローチ調査

TL;DR

今から着手すべき:MCTS/ロールアウト付きlook-aheadビームサーチ(offline 3分予算の質的活用)と、その延長としての「シミュレーション評価を最終段のみに使う二段構え探索」。現行の候補生成・スコア関数・リストスタート資産をそのまま乗せられ、5週間で検証まで到達可能。

並行検証すべき:BRKGA(Biased Random-Key Genetic Algorithm)。**decoder**に現行構築ヒューリスティックをそのまま使い、順序を進化させて実配置結果で評価するため、ALNS不採用の原因(代理評価の精度不足)を構造的に回避できる。offline専用。

着手すべきでない:ゼロから学習する深層強化学習(DRL)。推論コスト自体は制約内だが、GPU環境不明・学習数十時間〜数日・報酬設計・sim2realギャップ・提出形態(推論のみ・ネット遮断)の複合リスクで、5週間完走とpublic scoreへの反映の両立見込みが低い。

足切り(配置数の非線形効果)を踏まえると、「1個でも多く安定に置く」ことに直結する探索深化(B)とBRKGA(C)が最も期待値が高い。リスクを取ってDRLに飛ぶのではなく、探索レイヤーの高度化を主軸に据えるべきというのが本調査の明確な結論。

(A) 強化学習(RL)の現実的評価

概要と適合性

オンライン3D-BPPはDRLの主戦場で、代表研究が揃っている。**Zhao et al. (AAAI 2021, "Online 3D Bin Packing with Constrained Deep Reinforcement Learning")** は制約付きMDPとしてactor-criticで解き、feasibility mask(予測マスク)で実行不能行動を抑制する。同論文本文は、ヒューリスティック手法(Height-Vector, Item-Sequence-Vector)に対し「利用率+16.0%/+19.1%、配置数+4.3個/+5.0個」("16.0% and 19.1% higher space utilization and 4.3 and 5.0 more items packed than HV and ISV, respectively")と報告している。後続の**PCT (Packing Configuration Tree, ICLR 2022)** は木構造表現で連続空間・実務制約に対応。**GOPT(Xiong et al., IEEE Robotics and Automation Letters vol.9 no.11 pp.10335-10342, 2024; arXiv:2409.05344)** はPPOベースのactor-critic + Packing Transformerで、10×10×10ビンで利用率76.1%(ヒューリスティック51~58%、旧DRL 70~73%に対して)を報告。報酬は「各アイテム追加時の空間利用の増分」("the incremental improvement in space usage with each added item")。 [ICLR](#)

本プロジェクトとの適合性は**部分的**。到達可能性制約・搬入経路(L字軌道)・優先/ソフト手荷物の下敷き禁止といった多属性制約は、既存DRLが標準的に扱う「高さマップ+安定性マスク」より複雑で、報酬・状態設計を大幅に拡張する必要がある。

計算資源・学習時間(文献値、いずれもGPU前提)

Zhao et al. 2021: Titan V(12GB)で解像度10×10で約16時間、推論は1手10ms未満。 [arxiv](#)

GOPT 2024: RTX 3090で約6時間で収束(128並列環境・1000エポック)。

Zhao et al. 物理環境版: 非同期RL加速で約48時間で成熟方策。

CPUのみでの学習は現実的でない。

推論コスト

推論自体は軽量(PCT/Zhaoで1手10ms未満)で、**online 8秒/手・offline 3分の制約内には余裕で収まる**。ネット遮断も、学習済み重みを同梱し推論のみ実行すれば技術的には可能(ただし評価基盤にPyTorch等が入る前提。numpyのみで前向き推論を書き直す手もあるが工数増)。

報酬設計の難しさ(非公開しきい値)

足切りしきい値が非公開である点はRLにとって本質的困難。一般的対処:

Potential-based reward shaping(Ng et al. 1999):最終スパース報酬(充填率・配置数)に、置いた体積・安定余裕などの密な補助報酬を加える。ただしreward hacking(代理報酬をハックして本来目的を外す)という典型的失敗に注意。

非公開しきい値を推測しない方針(本コンテスト制約)と整合的な設計:足切りは「配置数の非線形効果」なので、報酬を「1個安定に置くごとに+、崩れたら大きく-」という配置数最大化の密報酬にすれば、しきい値を逆算せずとも正しい方向へ最適化される。Fang et al.(後述)も「各配置がもたらす無駄体積を罰する補助報酬」を採用している。

5週間での完走可能性:率直な評価

推奨しない。(1) GPU環境の有無が不明で、無ければ詰み。(2) 到達可能性・多属性制約を組み込んだ環境実装+報酬設計+学習+チューニングで5週間はほぼ使い切り、public scoreへの反映検証の余地が乏しい。(3) 文献のDRL優位性は「単純箱・標準制約・利用率指標」で示されており、本コンテストの複雑な採点(動的安定性テスト、搬入経路)への転移は保証されない。(4) sim2realギャップ(学習用の簡易安定性判定と、本番の30cm変位/45度回転判定・1~3G揺動テストの乖離)が上乘せされる。**現行57.5→上位67.9のギャップをこの手段で5週間内に詰められる見込みは低い**。

唯一の例外:GPUがあり、かつ既存OSS(alexfrom0815/Online-3D-BPP-PCT、GOPT)をほぼそのまま使える形に問題を単純化でき、offline側の配置順序決定の補助として部分利用する場合のみ、限定的な余地がある。

(B) MCTS/ビームサーチの高度化 ← 最有力

概要と適合性

これは**現行資産と最も相性が良い**。既にEP/EMS候補生成 + beam構築があるので、そのbeamを「深さ方向のlook-ahead付き」に拡張する、あるいはMCTSのrollout評価に置き換えるのは、機構的に自然な発展。

Look-ahead付きビームサーチ:各手で候補位置を上位k本保持するだけでなく、数手先まで展開して部分パッキングの評価が最大の枝を選ぶ。offline 3分予算を「幅×深さ×リスタート本数」に配分できる。

MCTS:Fang et al. (KDD 2026, "Effective Online 3D Bin Packing with Lookahead Parcels Using MCTS"; arXiv:2601.02649、著者Jiangyi Fang/Bowen Zhou/Haotian Wang/Xin Zhu/Leye Wang、北京大学・ハルビン工大・JD Logistics) はlook-ahead付きオンライン3D-BPをMPC問題として定式化しMCTSで解き、要旨verbatimで「分布シフト下で**10%超**、オンライン運用で**平均4%**、最良ケースで**8%超の改善**」("achieving over 10% gains under distributional shifts, 4% average improvement in online deployment, and up to more than 8% in the best case")を報告。重要なのは、彼らのMCTSが「探索事前分布を動的に調整し、ロバストなランダム方策とオフライン学習済みRL方策を、look-aheadアイテムが学習データに出現する尤度に応じて混合

する」("a dynamic mechanism to adjust the exploration prior, balancing between a robust random policy and an offline-learned RL policy according to the likelihood of lookahead parcels appearing in the training dataset")点。**RLが無くてもランダムロールアウトで動く**設計であり、末端評価にRL criticを使うが、これは現行スコア関数で代替可能。 [arXiv](#)

↑
[arxiv](#)
↑

古典研究:**Edelkamp, Gath, Rohde (KI 2014)** はextreme points + NRPA(Nested Rollout Policy Adaptation)で3D packingの高さ最小化に適用(結果は「promising」との定性報告のみで具体数値は非公開)。**Li et al. (QMCTS, PRCV 2018)** はMCTSベースで、**最良ベースラインに対する平均利得は約0.1ポイントと小さく**("can achieve an average more 0.1% volume utilization gain when compared to the best algorithm")、C++実装でIntel i7(8コア)にて**1ケース約60秒**。QMCTSの教訓は「MCTSの優位は最良ヒューリスティックに対しては僅かだが、弱いヒューリスティックには一貫して勝つ」という点で、本プロジェクトの「頭打ちの構築ヒューリスティック」を底上げする用途に合致する。

rollout(シミュレーション)コストの抑制 ← 核心的課題

到達可能性制約下でのrolloutは重い。抑制策:

軽量な代理rollout:full physics(pybullet)ではなく、現行の幾何的安定性判定(支持面・重心)でrolloutし、最終候補のみ本物の判定で確認する二段構え。RoboBPP(arXiv:2512.04415)やCoPack(arXiv:2511.19932)、PCT系(arXiv:2504.04421)の研究も「静的ルールベースで探索し、遅いphysicsシミュは最終段/test-timeのみ」という設計を採る。PCT論文は「Isaac Gymの並列性はオンライン梱包では利点が乏しく、CPU-GPU同期コストが高い」と明言し、学習は物理なし・test-time検証のみ物理という結論を出している。

増分更新:EP/EMSの増分更新(前回リサーチで消化済み)をrolloutでも使い回し、1手あたりの候補評価を定数時間に近づける。

rootのみ深く:MCTSは根に近い手数だけ深く探索し、末端はgreedy playout(rollout policy = 現行スコア関数)で打ち切る。

ルート並列化:評価基盤は4 vCPU。独立したbeam/MCTSを4本走らせ最良を採るルート並列化は実装容易で確実。

実装コスト・効果・リスク

実装コスト:**中**。既存候補生成・スコア関数を再利用でき、探索ループの差し替えが主。5週間で検証まで到達可能。

期待効果:offline側で配置数+数個を狙える。足切りの非線形効果により、配置数の僅かな増加が複数指標を同時に押し上げる本コンテストでは、**期待値が最も高い**。

リスク:(1) rolloutコストが予算超過→深さ・幅の予算配分の慎重な設計が要る。(2) online 8秒/手ではMCTSの反復数が限られる→onlineは浅いlook-ahead(1~2手)+beam、offlineは深いMCTSと使い分ける。(3) 評価関数の精度がrollout品質を規定する点はALNSと同じ弱点だが、**MCTSは最終的に真の配置を打ち切りまで進めるため、代理評価の誤差が実配置で部分的に補正される(=ALNSの代理評価より頑健)**。

(C) メタヒューリスティクス(GA/BRKGA/SA、noisy-fitness対策)

ALNS不採用の原因への処方

ALNSは「代理評価関数の精度不足」で不採用とのこと。核心は**代理評価に頼らず、真の採点ロジック(自前の**

フルシミュレータ)で解を評価するか、代理評価の誤差(ノイズ)に頑健な探索にすること。

noisy-fitnessに頑健な探索

評価が「ノイズ付き」(=代理評価≒真値+誤差)である状況に対する定石(Qian et al., "Analyzing Evolutionary Optimization in Noisy Environments", Evolutionary Computation 26(1):1, 2018 ほか):

再評価(re-evaluation):有望解を複数回/複数条件で評価し平均を取る。

しきい値選択(threshold selection):新解が現解を「一定マージン以上」上回るときのみ採択(ノイズによる誤採択を抑える)。

リサンプリング/統計的比較:候補間の順位を統計検定で決める。

重要な知見:**進化計算(GA/BRKGA/SA)**はランダム探索ヒューリスティックであり、問題特化の決定論的アルゴリズムよりノイズに本質的に頑健とされる。母集団を持つGA/BRKGAは、ALNSの「壊して直す」単一解軌道よりノイズ平均化効果で有利な場合がある。 [ACM Digital Library](#)

↑

BRKGA(Biased Random-Key GA)← Cの中で最有力

Gonçalves & Resende, "A biased random key genetic algorithm for 2D and 3D bin packing problems", **Int. J. Production Economics 145(2):500-510 (2013)** は、maximal-space表現を用い、tabu search・GRASP+VNDを含む既存手法を統計的に上回った。同論文は「858問題インスタンスで広範に検証」("extensively tested on 858 problem instances")し、要旨で「一貫して他手法と同等以上、統計解析で有意に優れる」("consistently equals or outperforms the other approaches and the statistical analysis confirms that the approach is significantly better")と述べる(著者公開ページによればbin数を3D:9803→9772、2D:7241→7234に削減とされるが、この具体数値は一次査読本文では未確認のため参考値扱い)。BRKGAレビュー(arXiv:2312.00961)も「tabu search・local search・GRASP+VNDを統計的に上回る」と要約している。

本問題への適合性(決定的):BRKGAは「箱の詰め順(とパラメータ)をrandom-keyで進化させ、decoder(=現行の構築ヒューリスティック)で実配置に変換」する。**decoderに現行アルゴリズムをそのまま使える**うえ、探索対象は「順序」で、代理評価ではなく**実際に置いた結果(真のdecoder出力)**で評価するため、ALNSの弱点を回避できる。 [ScienceDirect](#)

↑

実装コスト:中。random-key表現+エリート/交叉のGA骨格は軽量(参考OSS: dasvision0212/3D-Bin-Packing-Problem-with-BRKGA)。decoderは既存。 [GitHub](#)

↑

リスク:decoder1回=フル構築なのでoffline 3分では評価回数が限られる(母集団×世代で数百～千回程度)。母集団サイズ・世代数の予算配分が要。**onlineには不向き(offline専用)。**

GRASP/Path-Relinking、GRASP/VND

Alvarez-Valdes / Parreño / Tamarit系(Ann. Oper. Res. 2010; Comput. Oper. Res. 2013)。GRASP自体は「ランダム化構築+局所探索」で、**現行のRestricted Candidate List化リスタートは既にGRASPの構築フェーズそのもの**。未実装の伸びしろは**Path-Relinking**(エリート解間を補間して新解を得る)と**VND**(複数近傍を系統的に切り替える局所探索)。GRASP/VND(Parreño et al. 2010)は「既存最良ヒューリスティックと同等以上、かつ高速」と報告され、第三者ベンチ(Zhu et al. EJOR 2012)では約32秒でGRASP相当品質に到達との記述がある。ただし配置後処理の局所並べ替えは既に2回ノイズレベルだったので、VNDの近傍設計は慎重に。 [UV](#)

↑

SA(Simulated Annealing)

順序符号化(packing sequence)上でSAを回す構成が古くからあり、堅牢で実装容易(非導関数手法で局所最適を回避しやすく、GAよりやや計算コストが低いとされる)。ただし期待効果はBRKGA/GRASPと同程度かやや劣り、目新しさは薄い。**BRKGAを優先**すべき。

(D) その他の有望アプローチ

物理シミュレーション駆動の後処理(pybullet):Que et al.("Dynamics simulation-based packing of irregular 3D objects", Computers & Graphics 2024)は、まず幾何ヒューリスティック(DBLF + FFTベースの衝突計算)で初期配置を作り、「コンテナを揺らす+空隙充填」を物理シミュで行い、より密で安定な配置に収束させる。**本コンテストの動的安定性テスト(1~3G揺動)と評価軸が一致するため、採点器と同じ物理で最適化できる点**が強力。pybullet利用可という制約とも合致。実装コスト:中~大(シミュ速度が律速)。offline側の最終段仕上げ、または動的安定性スコアの底上げに向く。

到達可能性/搬入経路を明示的に扱う制約設計:Wang & Hauser(RSS 2019 "Stable bin packing of non-convex 3D objects with a robot manipulator"; TRO 2021 "Dense Robotic Packing")、およびロボットアーム workspaceをアルゴリズムのlayer widthに連結する手法(Jiao et al. 2024)、"Solving a large-scale 3D packing problem with robot constraints"(Comput. & Oper. Res. 2025、working range・衝突・干渉を明示考慮)。これらは「搬入機構と既配置物の干渉」を候補生成段でフィルタする設計を与える。前処理的な性格が強く前回消化済みレイヤーに近いが、L字軌道干渉を候補生成で先取りできれば無効手の削減になる。なお、Wang & Hauserは「robot-packable制約下でも物理シミュで80%の配置計画が実行成功(標準ソルバは17%)」と報告しており、到達可能性を候補段で担保する価値を示す。

列生成/matheuristic:配置を「パターン(列)」として扱い集合被覆的に選ぶ。理論的には強いが、非公開採点・動的安定性を線形モデルに落とし込みにくく、5週間では非現実的。**非推奨**。

総合的な推奨

結論:リスクを取ってDRLに飛ぶのではなく、「探索レイヤーの高度化(B)」を主軸に、「BRKGA(C)」を並行検証し、余力があれば「物理シミュ後処理(D)」を上乗せする段階戦略を推奨する。

理由:

現行の候補生成・スコア関数・リスタートという資産を捨てずに、その上に「深い探索(look-ahead/MCTS rollout、BRKGAのrandom-key順序探索)」を乗せる方向が、限られた5週間で最も期待値が高い。

足切り(配置数の非線形効果)が効く本コンテストでは、「1個でも多く安定に置く」ための探索深化が複数指標を同時に押し上げる。B・Cはいずれも配置数の直接改善を狙える。

B・Cとも**代理評価の精度に本質依存しない**(MCTSは末端まで実配置を進め、BRKGAはdecoderの実出力で評価する)ため、ALNS不採用の原因を構造的に回避できる。

DRLは推論コストこそ制約内だが、GPU不明・学習時間・報酬設計・sim2real・提出形態の複合リスクで、5週間完走とpublic score反映の両立が困難。

段階的アクションと判断基準

第1週:offline側にlook-ahead付きビームサーチ(深さ2~3、幅は現行beam幅程度)を実装。rolloutは幾何評価の

み、最終候補だけ本物の安定性判定。→ **判断基準**: ハイインスタンスで配置数が現行greedy/beamを1個以上安定に上回るか。上回れば深さ・幅を予算内で増やす。

第2〜3週: MCTS化(ルート並列4本、rollout policy=現行スコア関数、末端=スコア関数評価)。online側は浅いlook-ahead(1手)に留める。→ **判断基準**: 本番public scoreで+0.5点以上。頭打ちなら幅/深さ配分を変える。

第2〜4週(並行): BRKGAをoffline専用で実装(decoder=現行構築)。母集団30〜50、世代数は3分予算で回る範囲。noisy対策としてエリート再評価としきい値選択を導入。→ **判断基準**: BRKGAの最良解が単純リスタートの最良解を安定に上回るか。

第5週: 最も伸びた1系統に絞って予算配分チューニング+安定性確認。余力があればpybulletの「揺らし+空隙充填」後処理を最終段に追加(動的安定性スコアの底上げ狙い)。

撤退ライン: MCTS/look-aheadが第2週末で配置数改善ゼロ(ノイズレベル)なら探索深化は打ち切り、BRKGA一本に絞る。両方ダメなら、静的パラメータで有効だった重心オフセット許容量周辺の再探索と、物理後処理(D)に回帰する。

参考文献・実装

Zhao et al., "Online 3D Bin Packing with Constrained Deep RL", AAAI 2021 (arXiv:2006.14978)。実装: github.com/alexfrom0815/Online-3D-BPP-DRL

Zhao, Yu, Xu, "Learning Efficient Online 3D Bin Packing on Packing Configuration Trees", ICLR 2022 (arXiv、OpenReview id=bfuGjlCwAq)。実装: github.com/alexfrom0815/Online-3D-BPP-PCT

Zhao et al., "Deliberate Planning of 3D Bin Packing on Packing Configuration Trees", 2025 (arXiv:2504.04421)

Xiong et al., "GOPT: Generalizable Online 3D Bin Packing via Transformer-based DRL", IEEE RA-L 9(11):10335–10342, 2024 (arXiv:2409.05344)

Fang et al., "Effective Online 3D Bin Packing with Lookahead Parcels Using MCTS", KDD 2026 (arXiv:2601.02649)

Edelkamp, Gath, Rohde, "Monte-Carlo Tree Search for 3D Packing with Object Orientation", KI 2014 (Springer LNCS 8736)

Li, Wang, Ma, Fang, Lei, "Quasi-Monte-Carlo Tree Search for 3D Bin Packing", PRCV 2018 (Springer LNCS)

Gonçalves & Resende, "A biased random key genetic algorithm for 2D and 3D bin packing problems", Int. J. Production Economics 145(2):500–510, 2013。参考実装: github.com/dasvision0212/3D-Bin-Packing-Problem-with-BRKGA

Parreño et al., "A hybrid GRASP/VND algorithm for 2D and 3D bin packing", Ann. Oper. Res. 179:203–220, 2010; Alvarez-Valdes, Parreño, Tamarit, "A GRASP/Path relinking algorithm...", Comput. Oper. Res. 40(12):3081–3090, 2013

Qian et al., "Analyzing Evolutionary Optimization in Noisy Environments", Evolutionary Computation 26(1):1, 2018

Que et al., "Dynamics simulation-based packing of irregular 3D objects", Computers & Graphics 2024

Wang & Hauser, "Stable bin packing of non-convex 3D objects with a robot manipulator", 2019

(arXiv:1812.04093); "Dense Robotic Packing of Irregular and Novel 3D Objects", IEEE TRO 2021

"Solving a large-scale 3D packing problem with robot constraints", Computers & Operations Research 2025

RoboBPP (arXiv:2512.04415)、CoPack (arXiv:2511.19932): pybulletベースの物理検証ベンチ/学習(rollout高速化・test-time物理検証の設計例)

注記(出典の確度):MCTS(Fang et al.)とBRKGA(Gonçalves & Resende)、DRL(Zhao/GOPT)の性能数値は要旨・本文verbatimで確認済み。BRKGAの具体bin削減数(9803→9772等)は著者公開ページ由来で一次査読本文では未確認のため参考値。QMCTS・GRASP系の一部の細かな数値・古典MCTS(Edelkamp 2014)の定量結果はペイウォールにより一次確認できず、定性記述にとどめた。これらのベンチマークは実装言語・ハードウェアが異なるため、絶対値の直接比較は避け、本プロジェクトでの実測(public score)で判断すべきである。